

基于灰度共生矩阵的图形纹理检测及焊接缺陷的 SVM 分类实现

陈 滔^{1,2}, 张庆国^{3*}, 刘 澳⁴

(1. 安徽农业大学 工学院, 安徽 合肥 230036; 2. 甘肃政法大学 民商经济法学院, 甘肃 兰州 720070;
3. 安徽医科大学 临床医学院, 安徽 合肥 230031; 4. 安徽农业大学 信息与计算机学院, 安徽 合肥 230036)

摘 要: 工业 4.0 时代, 焊接技术作为一种最基本的工件加工技术, 被广泛应用于各种工业生产。焊接质量直接影响焊接产品的使用寿命, 从而影响工业生产活动的效率。基于灰度共生矩阵 (GLCM) 对 X-射线焊接缺陷图像进行特征提取, 分析 X-射线焊接缺陷的分类特点, 构建 SVM 多类分类器, 分析对比不同核函数对分类精度的影响。基于 RBF 核函数的 SVM 分类器能够对焊接缺陷进行良好的识别分类, 总体分类精度达到了 92.6%, 为焊接缺陷的检测识别提供了一种简便的方法。

关键词: 缺陷识别; 特征提取; SVM 分类; 核函数

DOI: 10.3969/j.issn.1674-5043.2022.01.010

中图分类号: TP391.4; TG441.7

文献标识码: A

文章编号: 1674-5043(2022)01-0053-09

焊接是一个具有极大不确定性、受诸多影响的过程。由于各种复杂因素的影响, 导致焊接缺陷的位置、大小、形状和方向等具有极大的不确定性。目前, 在焊接缺陷检测方面, 常用的检测方法主要有目视检测法、射线检测法、超声波检测法、磁通检测法^[1]。目视检测是最为传统和常用的检测方法, 凭借一些常规的检测工具如量尺和放大镜等, 依靠工作人员的眼肉和工作经验来判断产品质量是否合格, 这种检测方式操作简单、灵活性强, 但太依赖于劳动者^[2]。射线检测除非在一个封闭的范围内, 否则长期下去将会危害工作人员的健康, 并且封闭空间的造价十分昂贵, 不适合现场缺陷检测。超声波检测灵敏度高、速度快, 但对环境要求很高, 实际生产现场受到各种噪声影响, 使得超声波检测难以达到要求。磁通检测是通过电磁来实现缺陷检测, 虽然有一定的优越性, 但对生产现场造成的电磁污染将会很大, 不利于绿色生产和环保^[3]。

机器视觉检测是近年来比较热门的一种检测方式, 能够有效降低生产成本, 提高产品生产效率, 保证产品的质量。高顶等^[4]提出了一种基于粗糙模糊-神经网络的缺陷识别算法, 充分利用了粗糙集的属性约简、模糊集的处理不精确数据, 以及神经网络的自学习、对任意函数逼近的优点, 有效地提高了焊缝图像的缺陷识别能力。郭文明等^[5]为了实现 X-射线图片的焊接缺陷检测, 采用基于目标检测领域的 Faster R-CNN 的目标检测方法, 为实现焊接缺陷的自动识别和定位进行了实验性的尝试。

本文基于计算机识别技术, 借助灰度共生矩阵理论, 分析共生矩阵各个构造参数对构造共生矩阵的影响, 实现对 X-射线焊接缺陷图像的纹理特征的提取, 基于特征提取结果, 对比不同核函数对焊接缺陷分类的影响, 寻求一个最优的 SVM 焊接缺陷识别分类方案。

1 总体架构

X-射线焊接缺陷图像检测识别流程如图 1 所示。以 X-射线的焊接缺陷为研究对象, 通过灰度共生矩阵理论对焊接缺陷图像进行纹理特征的提取, 然后以 SVM 算法作为核心, 对焊接图像的特征提取及其分

收稿日期: 2021-06-06

作者简介: 陈 滔 (1998-) 男, 贵州毕节人, 本科, 工程师, 主要从事气象环境设计与图像处理方面的研究. E-mail: chen.t1998@foxmail.com

通讯作者: 张庆国 (1959-) 男, 江西玉山人, 博士, 教授, 硕士生导师, 主要从事应用数学方面的研究. E-mail: qing-guo_zhang@163.com

基金项目: 安徽农业大学“优才计划”科研发展资助项目 (XSZZ202006); 安徽省学术和技术带头人及后备人选学术科研活动经费 (2016H072)。

类深入研究。建立灰度共生矩阵模型,对灰度共生矩阵的二阶矩、对比度和相关度等参数进行分析,通过实验验证了纹理特征提取的有效性。同时,分析不同核函数对 SVM 分类效果的影响,通过对比原始图像和特征图像的分类结果,验证对 X-射线焊接缺陷图像进行纹理特征提取后进行 SVM 分类的可行性和优良性。

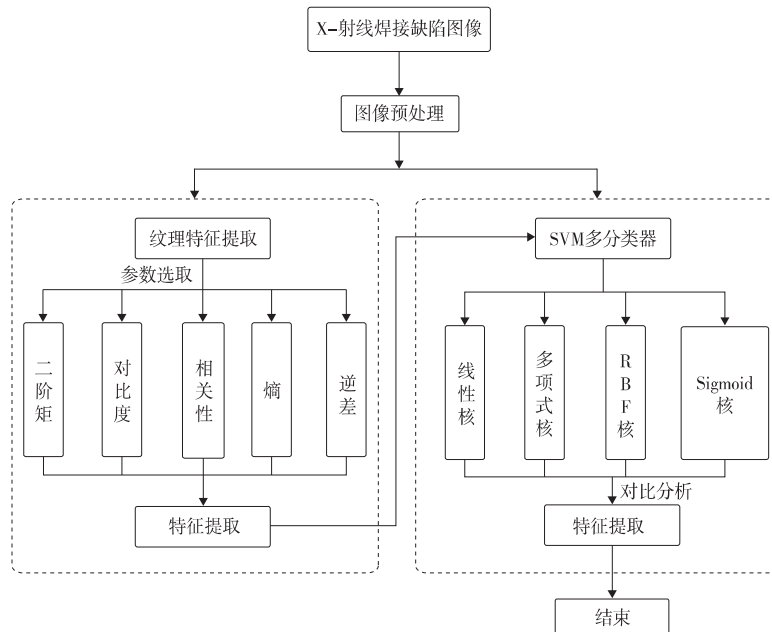


图 1 X-射线焊接缺陷图像检测识别流程

2 灰度共生矩阵理论

灰度共生矩阵能够提取出焊接缺陷图像关于方向、局部纹理排列规律、纹理变化规则等综合信息^[6-10]。为了更直观地利用灰度共生矩阵描述焊接缺陷的纹理特征,通常情况下不直接应用计算得到共生矩阵,而是基于该矩阵进行统计计算提取相应的统计特征。Haralick^[11]定义了和平均、和方差、对比度等 14 个统计学参数用于描述灰度共生矩阵的纹理特征。但 Ulaby 等^[12]在后续研究中发现,仅能量(二阶矩)、对比度、相关度和熵这 4 个统计特征是不相关的,并且基于这 4 种特征参数的图像识别分类精度相当高。基于 Ulaby 等的研究^[12],补充逆差作为 X-射线焊接缺陷图像的纹理特征参数之一。灰度共生矩阵定义为原始图像灰度为 i 的点到灰度为 j 的点的概率,其中 i 和 j 满足固定的位置关系 $d = (\Delta x, \Delta y)$,一般用 $P_d(i, j)$ ($i, j = 0, 1, \dots, L-1$) 表示, L 为灰度级。在规定好位置关系 d 后,还需要规定灰度共生矩阵的生成方向 θ , 通常情况下 θ 取 0° 、 45° 、 90° 和 135° , 如图 2 所示。




图 2 灰度共生矩阵像素对关系

设图像为 $l(M, N)$, 其中任意一点为 $A(x, y)$ 及偏离它的一点为 $B(x + dx, y + dy)$; 设 A 点对应的灰度值为 $l_i(x, y)$, B 点对应的灰度值为 $l_j(x + dx, y + dy)$ 。假设点 (x, y) 在整个图片中移动, 会得到各种各样的 (l_i, l_j) ($i \geq 0, j \leq L - 1$), 则 (l_i, l_j) 的组合有 $L \times L$ 种。对于整个 X-射线焊接缺陷图像, 统计出每种 (l_i, l_j) 出现的次数, 然后排列成一个矩阵, $G(l_i, l_j)$ 为每一种 (l_i, l_j) 出现的次数, 则总次数为:

$$Z = \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} G(l_i, l_j) \quad (1)$$

假设 $P_{L \times L}$ 中每一个元素

$$C(l_i, l_j) = \frac{G(l_i, l_j)}{Z} \quad (2)$$

那么 $P_{L \times L}$ 为灰度共生矩阵, 且

$$P_{L \times L} = \begin{bmatrix} C(l_0, l_0) & C(l_0, l_1) & \cdots & C(l_0, l_j) & \cdots & C(l_0, l_{L-1}) \\ C(l_1, l_0) & C(l_1, l_1) & \cdots & C(l_1, l_j) & \cdots & C(l_1, l_{L-1}) \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ C(l_i, l_0) & C(l_i, l_1) & \cdots & C(l_i, l_j) & \cdots & C(l_i, l_{L-1}) \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ C(l_{L-1}, l_0) & C(l_{L-1}, l_1) & \cdots & C(l_{L-1}, l_j) & \cdots & C(l_{L-1}, l_{L-1}) \end{bmatrix} \quad (3)$$

能量可用于度量各类不同焊接缺陷图像纹理的一致性, 反映图像灰度的分布特征和图像纹理特征的粗细, 常用 S_E 表示。X-射线焊接缺陷图像的灰度分布越均匀, 图像的纹理就越细致, 能量就越大; 反之, 灰度分布过于密集, 图像的纹理就会很粗糙, 能量就会很小。其计算方法为:

$$S_E = \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} \{P_d(i, j | d, \theta)\}^2 \quad (4)$$

对比度, 也称为惯性矩, 能够判断 X-射线焊接缺陷图像的纹理特征是否清晰以及其特征的深浅程度, 用 S_{Con} 表示。纹理特征深度越高, 对比度就越高; 纹理特征深度越低, 对比度就越低。从计算机视觉的角度来说, 一般情况下, 对比度高的图像就清晰。对比度的计算规则:

$$S_{Con} = \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} (i - j)^2 P_d(i, j | d, \theta) \quad (5)$$

相关度是度量 X-射线焊接缺陷局部灰度值相关度的统计常量, 可以在一定程度上反映出灰度共生矩阵各元素在行和列方向上的相似性, 用 S_{Cor} 表示。矩阵元素之间像素值相差越大, 相关度越大。

$$S_{Cor} = \frac{\sum_{i=0}^{L-1} \sum_{j=0}^{L-1} ij P_d(i, j | d, \theta) - \mu_1 \mu_2}{\sigma_1 \sigma_2} \quad (6)$$

其中:

$$\mu_1 = \sum_{i=0}^{L-1} i \sum_{j=0}^{L-1} P_d(i, j | d, \theta) \quad (7)$$

$$\mu_2 = \sum_{j=0}^{L-1} j \sum_{i=0}^{L-1} P_d(i, j | d, \theta) \quad (8)$$

$$\sigma_1^2 = \sum_{i=0}^{L-1} (i - \mu_1)^2 \sum_{j=0}^{L-1} P_d(i, j | d, \theta) \quad (9)$$

$$\sigma_2^2 = \sum_{j=0}^{L-1} (j - \mu_2)^2 \sum_{i=0}^{L-1} P_d(i, j | d, \theta) \quad (10)$$

熵是对 X-射线焊接缺陷图像的复杂程度进行解释的统计量, 能够提取纹理特征的随机性。熵值越大, 图像的纹理信息就越多, 随机性就越大。其计算方法为:

$$S_s = - \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} P_d(i, j | d, \theta) \cdot \lg P_d(i, j | d, \theta) \quad (11)$$

逆差用于反映 X-射线缺陷图像纹理的同质性,解释图像纹理局部变化特征。其值大则说明图像纹理的不同区域间缺少变化,局部非常均匀。其计算公式为:

$$D = \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} P_d(i, j | d, \theta) \frac{1}{1 + (i - j)^2} \quad (12)$$

3 SVM

SVM 在分类中具有很多优势,通过寻找特征空间上的最大间隔来定义生成分类器^[13]。SVM 通过构建一个超平面如图 3 所示。小菱形和小三角形分别为 2 类样本, H 为分类线, H_1 、 H_2 分别为过分类样本离分类线最近且平行于分类线的直线, H_1 和 H_2 之间的距离称为分类间隔。当分类线能够精确将两类样本区分开且 H_1 和 H_2 之间的距离最大时,就得到了最优分类面。分类线的数学定义为: $\omega x + b = 0$, 其中 ω 和 b 分别表示分类面的法向量和截距。




图 3 SVM 在特征空间上的二分类

对于给定的数据集 $X = \{X_1, X_2, \dots, X_i, \dots, X_n\}$, $X_i = \{x_1, x_2, \dots, x_i, \dots, x_n\}$, 学习目标 $y = \{y_1, y_2, \dots, y_n\}$, 其中 $y_i \in [-1, 1]$ 。每个样本都具有多个不同的特征空间,分类面会有很多种,本文选定满足 $\|\omega\|$ 最小的二分类平面作为最优分类面。线性 SVM 的损失函数可以用以下数学方法表示:

$$\begin{cases} \min & (\frac{1}{2} \omega^T \omega + C \sum_i \xi_i) \\ \text{s.t.} & y_i(\omega^T x_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0 \quad i = 1, 2, \dots, l \end{cases} \quad (13)$$

其中: ξ 表示松弛变量,作为 SVM 的约束条件。当 ξ 充分大时,模型满足上述条件,但为了避免 ξ 取值过大导致分类结果失真,引入了惩罚项 $\sum_i \xi_i$, $C(C > 0)$ 为惩罚系数。

当分类面也满足条件 $y_i \omega^T x_i \geq 1 - \xi_i \geq 0 \quad i = 1, 2, \dots, l$ 时,线性 SVM 的损失函数改写为:

$$\begin{cases} \min & [\frac{1}{2} \omega^T \omega + C \sum_i \max(0, 1 - y_i \omega^T x_i)] \\ \text{s.t.} & y_i \omega^T x_i \geq 1 - \xi_i \geq 0 \quad i = 1, 2, \dots, l \end{cases} \quad (14)$$

采用 SDG 随机梯度优化算法^[14]对 SVM 分类问题进行求解,需要随机选择一个样本作为 SVM 参数的更新迭代,此时的损失函数为:

$$\begin{cases} \min & [\frac{1}{2}\omega^T\omega + \frac{C}{l}\sum_i^l \max(0, 1 - y_i\omega^T x_i)] \\ \text{s.t.} & y_i\omega^T x_i \geq 1 - \xi_i \geq 0 \quad i = 1, 2, \dots, l \end{cases} \quad (15)$$

每次采用一个随机样本对 SVM 进行梯度更新, 这样就不需要对整个数据集进行学习, 很大程度上提高了 SVM 的学习能力, 对上式求梯度得:

$$\nabla_i = \omega - I[y_i\omega^T x_i > 1] \frac{C}{l} y_i x_i \quad (16)$$

式中: 第二项是指示项, 在满足 $y_i\omega^T x_i > 1$ 时函数值为 1, 反之为 0。因此, 迭代公式为:

$$\omega^{(i+1)} = \omega^t - \eta_t \nabla_i = \omega^t - \eta_t \omega + I[y_i\omega^T x_i > 1] \frac{C}{l} y_i x_i \quad (17)$$

其中: $\eta_t = \frac{\eta_0}{(1 + \lambda\eta_0 t)}$; $\eta_0 = 1$; η 为步长, 决定了 SVM 需要迭代多少次才能寻找到最优分类面。SVM 分类模型中核函数决定了其机器学习的泛化能力, 好的核函数能够提高 SVM 的数据处理能力, 通过映射, 使得 X-射线焊接缺陷图像变得线性可分, 核函数的作用就是用于定义这种映射。理论上任何一个满足 Mercer 定理的函数都可以作为核函数^[15]。目前, SVM 分类领域使用最多的核函数有以下 4 类。

线性核函数: $k(x, x_i) = x \cdot x_i$

多项式核函数: $k(x, x_i) = (x \cdot x_i + 1)^d, d \in N_+$

RBF 核函数: $k(x, x_i) = \exp\left(-\frac{\|x - x_i\|}{\delta^2}\right)$

Sigmoid 核函数: $k(x, x_i) = \tanh(\eta \langle x, x_i \rangle + \theta)$

4 实验结果及分析

实验所用数据集来自于公开数据库的 GDXray 中 welds 组^[16]。从该数据集中的 88 张射线图像中裁剪出 500 张的焊接缺陷图像, 包括未焊透、气孔、夹渣和裂纹各 100 张缺陷图像以及 100 张无缺陷图像, 如图 4 所示。由于缺陷图像数据集来自于 GDXray 数据库, 故不需要再进行图像预处理等操作。




图 4 X-射线焊接缺陷图像示例

4.1 特征提取结果分析

确定对 X-射线焊接缺陷提取表面纹理的灰度共生矩阵构造方式后, 利用 MATLAB 2018b 进行编程, 并对研究使用的图像数据集进行 4 个方向上的灰度共生矩阵, 其中取位置关系 $d=1$ 。基于灰度共生矩阵提取结果进行了 5 个纹理特征量的计算, 获取了 X-射线焊接缺陷图像的 5 个纹理特征参数, 如图 5 所示。

通过图像可以看出, 代表裂纹和夹渣两种缺陷的能量曲线距离相差较大, 裂纹缺陷的能量值整体上要比夹渣缺陷的能量值大, 说明裂纹的纹理特征相较于夹渣的纹理特征要均匀, 可以通过能量区分出 2 种曲线的种类。

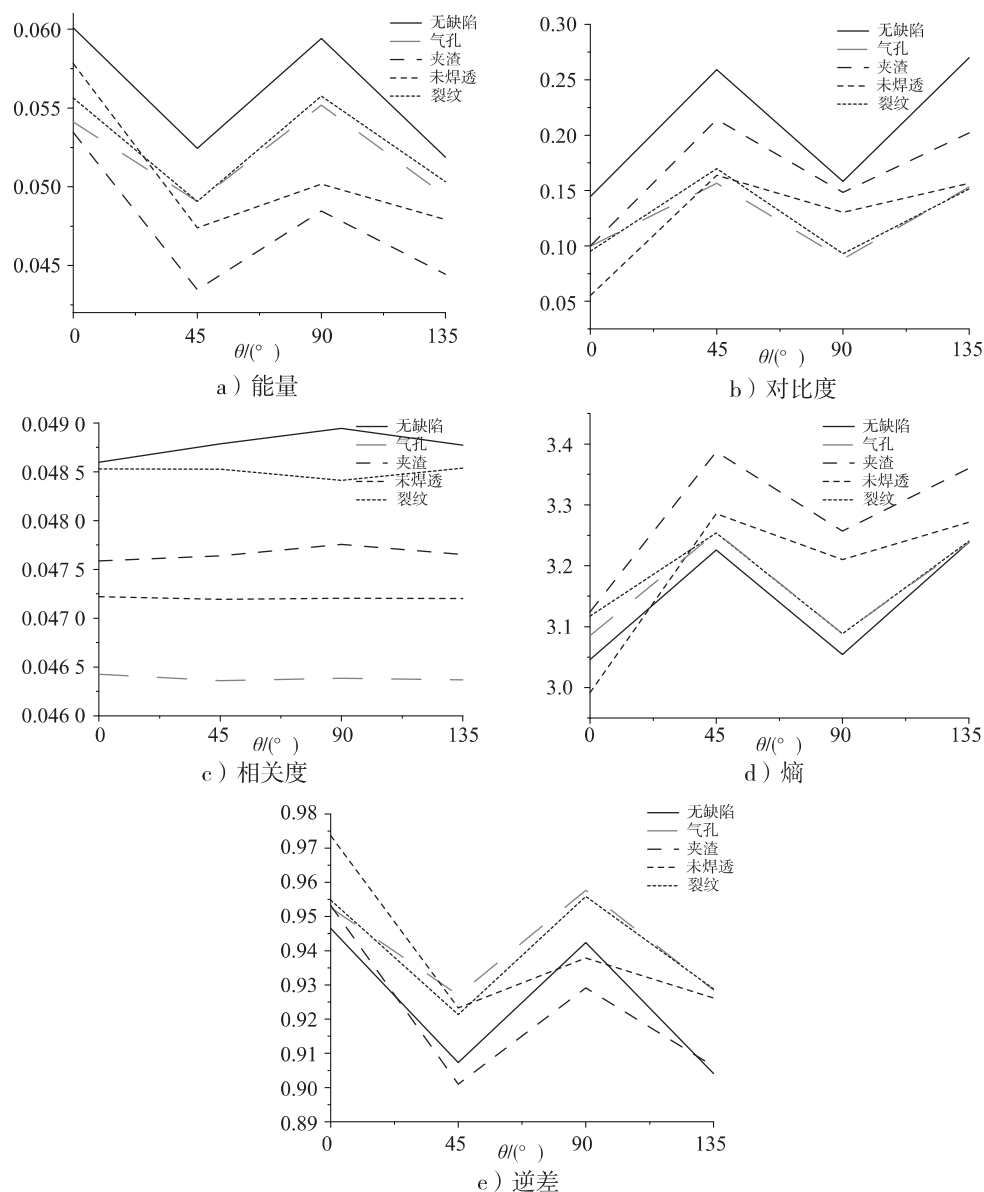


图 5 X-射线焊接缺陷图像的 GLCM 纹理特征提取结果

不同焊接缺陷图像的清晰度没有特别大的差异,也就是不同焊接缺陷的纹理特征深浅程度差距并不明显,相对而言,裂纹的纹理特征较深,其对比度较大。

不同 X-射线焊接缺陷图像的相关度,用以解释焊接缺陷图像灰度共生矩阵中的各元素在行和列的相似水平,该值的大小一定程度上表现焊接缺陷图像局部灰度的关联性。由图中不同生成方向的相关度值可以知道,裂纹的相关度高于其他焊接缺陷图像。根据不同 X-射线焊接缺陷的相关度曲线,可以将缺陷图像分为 3 个大类:裂纹和无缺陷图像、夹渣和未焊透图像、气孔图像。

对比不同 X-射线焊接缺陷图像的熵特征参数曲线,夹渣的熵值最高,说明其图像中的灰度差异较大。对未焊透缺陷来说,其在水平方向的灰度差异最小,其他方向上的熵值均整体高于气孔、裂纹和无缺陷图像,仅次于夹渣图像,其图像中的灰度差异也较明显。裂纹和气孔的熵值十分接近,说明它们之间的灰度差异程度相当,无法用熵值特征对这两种焊接缺陷进行检测识别。无缺陷图像由于其 X-射线图像表面光滑,其纹理随机性小,熵值也整体较低。

各焊接缺陷图像逆差特征区分度并不明显,但可以表现出不同焊接缺陷图像在不同方向上的局部变化规律。因此,可以将逆差特征参数与其他纹理特征参数结合进行对 X-射线焊接缺陷图像进行分类识别。

通过上述分析,使用能量、对比度、相关度、熵和逆差能够有效对 X-射线焊接图像进行识别分类。

本研究是为了对不同 X-射线缺陷图像的纹理特征进行检测识别，分类精度越高越好。因此，对上述特征参数值分别求取均值和方差作为特征参数以抑制生成方向 θ 对特征提取结果的影响，保证后续对焊接图像进行 SVM 分类时能够得到更加精确的结果，结果如表 1 和表 2 所示。

表 1 GLCM 特征参数的均值

	无缺陷	气孔	夹渣	未焊透	裂纹
能量	0.055 953	0.051 951	0.047 454	0.050 829	0.052 697
对比度	0.207 938	0.124 391	0.166 163	0.126 430	0.127 313
相关度	0.048 776	0.046 385	0.047 658	0.047 205	0.048 503
熵	3.141 098	3.175 158	3.282 154	3.189 730	3.166 780
逆差	0.925 096	0.941 471	0.922 420	0.940 234	0.940 215

表 2 GLCM 特征参数的方差

	无缺陷	气孔	夹渣	未焊透	裂纹
能量	0.004 394	0.003 150	0.004 549	0.004 816	0.003 504
对比度	0.065 747	0.035 464	0.052 554	0.049 594	0.039 198
相关度	0.000 142	0.000 029	0.000 071	0.000 012	0.000 060
熵	0.105 490	0.084 212	0.118 935	0.136 069	0.092 246
逆差	0.022 435	0.015 935	0.023 915	0.023 144	0.017 730

4.2 SVM 分类结果分析

传统支持向量机仅仅适用于二分类问题，而对 X-射线焊接缺陷的分类是一个多类分类问题，因此需要构造一个多类分类器。将二分类 SVM 构造成多分类 SVM，通常情况下有 2 种方法：一是使用多个二分类 SVM 进行合理的组合，然后组合出多分类 SVM^[17-18]；二是通过改写传统 SVM 的目标函数，对全局变量进行优化求解，直接构造出一个多分类 SVM^[19-21]。由于第二种方法在求解全局优化解时过于复杂，其变量数远超过第一种方法，同时训练速度和分类精确度相较与第一种方法来说效果较差。因此，选取第一种方法构造多类 SVM 分类器，如图 6 所示。图中 5、4、3、2 和 1 分别代表无缺陷、气孔、夹渣、未焊透和裂纹的 X-射线图像。

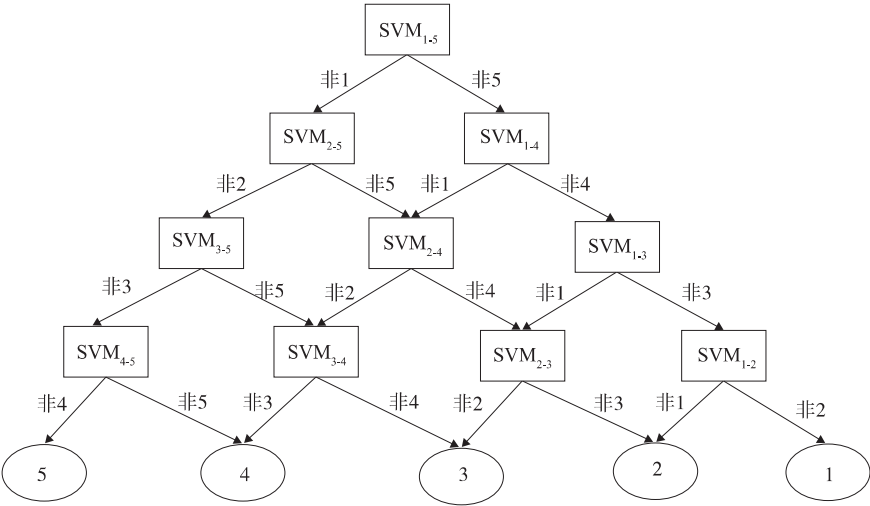


图 6 X-射线缺陷图像的 SVM 多类分类器

SVM 分类器在分类过程中，需要先利用训练集使支持向量机进行学习，然后再对 X-射线焊接缺陷图像进行检测识别。本节对不同的焊接缺陷图像随机抽取各 50 张图像作为训练集，所有的 X-射线焊接缺陷图像作为验证集进行实验，具体流程如图 7 所示。




图 7 SVM 分类器工作流程

为了对比基于不同核函数的支持向量机对 X-射线焊接缺陷的分类效果，采用 *Kappa* 系数^[22]作为指标量化分析不同核函数的分类准确率，其值越高，分类效果越好。

$$Kappa = \frac{p_0 - p_e}{1 - p_e} \tag{18}$$

其中： p_0 为一致性单元的比例， p_e 为期望偶然一致的单元比例。

本文研究的 4 种核函数对不同焊接缺陷的分类性能对比如表 3 所示。

表 3 基于 GLCM 特征的 X 射线焊接缺陷 SVM 分类结果

		无缺陷	气孔	夹渣	未焊透	裂纹	正确率/%	总体精度/%	<i>Kappa</i>
线性核	无缺陷	90	0	1	0	9	90	85	0.813
	气孔	3	78	5	14	0	78		
	夹渣	0	0	93	7	0	93		
	未焊透	6	3	5	77	9	77		
	裂纹	0	0	0	13	87	87		
多项式核	无缺陷	89	0	4	6	1	89	85	0.824
	气孔	0	71	0	3	26	71		
	夹渣	0	5	85	6	4	85		
	未焊透	0	5	3	92	0	92		
	裂纹	0	0	3	9	88	88		
RBF 核	无缺陷	93	2	5	0	0	93	92.6	0.866
	气孔	0	87	0	0	13	87		
	夹渣	0	0	98	2	0	98		
	未焊透	0	3	1	96	0	96		
	裂纹	0	2	7	2	89	89		
Sigmoid 核	无缺陷	82	9	7	2	1	82	80.6	0.795
	气孔	9	78	1	0	12	78		
	夹渣	3	3	81	8	5	81		
	未焊透	10	4	4	79	3	79		
	裂纹	2	1	9	5	83	83		

从表 3 可以看出，基于线性核函数的 SVM 分类器对气孔缺陷和未焊透缺陷的错分情况较多，两者的正确率分别为 78%和 77%。气孔缺陷图像中有相当一部分被归类为未焊透缺陷，原因是气孔缺陷和未焊透缺陷的相关度特征参数极其相似，导致线性核函数无法精确地对两者进行线性归类；对夹渣的分类精度最高，达到了 93%，原因是由于夹渣的能量特征和熵特征均较其他缺陷图像有显著差异。

多项式核函数的总体分类正确率达到了 85%，与线性核函数的分类效果基本相似。多项式核函数的 *Kappa* 系数值为 0.824，略高于线性核函数，说明多项式核函数的 SVM 分类器较线性核函数的稳定，分类结果也更可靠。但气孔缺陷出现了很严重的错分情况，有 26%的气孔缺陷被错分为裂纹缺陷，这是由于气孔和裂纹的熵特征几乎相同，两者的纹理信息复杂度近乎相等，从而导致多项式核函数无法泛化区分

两者的熵特征。

与线性核函数和多项式核函数相比, RBF 核函数的分类效果得到了极大的改善, 总体分类正确率达到了 92.6%, $Kappa$ 系数值也高达 0.866。同时, RBF 核函数对气孔缺陷的识别分类得到一定程度上的改善, 降低了气孔缺陷图像的错分率, 其分类正确率达到了 87%, 但可以发现 RBF 依然不能很高水平的抑制对气孔缺陷的错分。相比而言, RBF 核函数的对各类焊接缺陷图像的分类识别均较为准确, 分类水平达到了很高的层次, 能够应用于 X-射线焊接缺陷图像识别领域。

Sigmoid 核函数对 X-射线焊接缺陷图像的分类能力稍弱于其他 3 种核函数, 总体分类精度也仅为 80.6%。显然, Sigmoid 核函数不能很清晰地对焊接缺陷图像的 GLCM 纹理特征进行识别划分。

5 结 语

针对 X-射线焊接缺陷图像从特征提取、特征参数删选、分类模型的构建等方面入手, 试图找寻合适的焊接缺陷图像特征提取和分类方法, 减少人工分类过程中各种不确定性因素的影响。在提取 X-射线焊接缺陷图像的 GLCM 纹理特征时, 还需要考虑图像灰度级对灰度共生矩阵计算的影响, 灰度级的选取决定着灰度共生矩阵的规模, 后续研究将对不同灰度级的缺陷图像进行纹理特征提取, 以便进一步提高焊接缺陷识别分类性能。同时, X-射线图像数据还需要增加, 虽然本文使用的数据集已经能够满足本文的研究需求, 但研究结论可能还存在轻微瑕疵, 在今后的研究中希望建立更大规模的数据集, 为后续研究奠定基础。

参考文献:

- [1] 陈强. 基于机器视觉的钢板焊缝缺陷检测方法研究[D]. 杭州: 浙江工业大学 2012: 18-25.
- [2] 郭俊磊, 魏艳红, 占小红, 等. X-射线焊缝缺陷自动识别系统的设计与开发[J]. 焊接 2013(5): 36-39.
- [3] 张波. 焊缝图像处理的研究[D]. 上海: 上海交通大学 2005: 10-15.
- [4] 高顶, 张长明, 李国庆, 等. 基于粗糙-模糊神经网络的焊接图像缺陷识别[J]. 华东理工大学学报(自然科学版) 2006(9): 1126-1129.
- [5] 郭文明, 刘凯, 渠慧帆. 基于 Faster R-CNN 模型 X-射线图像的焊接缺陷检测[J]. 北京邮电大学学报 2019 42(6): 20-28.
- [6] MEENAKSHI P, JHA C K, SAURABH M. Classification of Brain Tumor using GLCM and SVM from MRI Images [C]// Proceedings of the 6th International Conference on Mechanical, Aeronautical and Industrial Engineering. 2017: 142-149.
- [7] DWAICH H A, ABDULBAQI H A. Signature texture features extraction using GLCM approach in android studio [J]. Journal of Physics: Conference Series 2021 1804(1): 1-9.
- [8] 李蓉辉, 陈玲, 吴明晶, 等. 亚热带人工林高分影像 GLCM 纹理的应用策略研究[J]. 北京林业学报 2021 43(1): 1-9.
- [9] 石康君, 王静安, 高卫东. 织物褶皱多尺度灰度共生矩阵分析[J]. 丝绸 2020 57(2): 35-40.
- [10] EBENEZER O, OYEBADE K, CLEMENT A, et al. In-line grading system for mango fruits using GLCM feature extraction and soft-computing techniques [J]. International Journal of Applied Pattern Recognition 2019 6(1): 58-75.
- [11] HARALICK R M. Statistical and structural approaches to texture [J]. Proceedings of the IEEE 2005 67(5): 786-804.
- [12] ULABY F T, KOUYATE F, RISCO B B, et al. Textural information in SAR images [J]. IEEE Transactions on Geoscience and Remote Sensing 1986 24(2): 235-245.
- [13] 陶卿, 姚穗, 范劲松, 等. 一种新的机器学习算法: Support Vector Machines [J]. 模式识别与人工智能 2000 13(3): 285-290.
- [14] LIU Y, WEI H, ZHANG H, et al. An Efficient Stochastic Gradient Descent Algorithm to Maximize the Coverage of Cellular Networks [J]. IEEE Transactions on Wireless Communications 2019 18(7): 3424-3436.
- [15] 张学工. 关于统计学习理论与支持向量机 [J]. 自动化学报 2000(1): 36-46.
- [16] MERY D, RIFFO V, ZSCERPEL U, et al. The database of X-ray images for nondestructive testing [J]. Journal of Nondestructive Evaluation 2015 34(4): 1-12.
- [17] 张小洁, 张艳, 林育阳. 基于 SVM 的粉末冶金零件的多类分类器的研究[J]. 计算技术与自动化 2017 36(2): 33-36.
- [18] 李雪花, 许姜滢宇, 于安军, 等. 基于 SVM 多类分类器的字符识别[J]. 信息技术 2016(1): 20-22.
- [19] 孙少乙, 黄志波. 一种 SVM 多分类算法 [J]. 微型机与应用 2016 35(8): 12-14.

(下转第 67 页)

International Journal of Automation and Computing 2018 ,15(3) : 325–334.

[11] 程瑶 孙霞 孙朝鹏.智能门禁系统控制方法的分析与设计[J].洛阳理工学院学报(自然科学版) 2020 30(2) : 56–59.

Research on Anti-jamming of Multi-face Recognition Based on Keras Convolutional Neural Network

CHU Hui , SONG Chen , WANG Chencan

(School of Mechanical Engineering , Anhui University of Science & Technology , Huainan 232001 , China)

Abstract: There are many complicated face recognition training prediction models , with many factors influencing the accuracy and stability of face recognition. Anti-jamming technology research is essential to construct the face recognition models , which aim to get the quality data , selects face recognition optimizer and adjusts other parameters in order to improve the face data processing. Also , convolutional neural network is applied to reduce human intervention and improve the accuracy of feature extraction , realizing the multi-face recognition.

Keywords: face recognition; convolutional neural network; the optimizer; anti-interference

(责任编辑: 翟智卫)

~~~~~  
( 上接第 61 页)

[20] 刘铭.基于 CMABC 参数优化的 SVM 多分类入侵检测方法研究[D].南宁: 广西大学 2015: 20–25.

[21] 候明 张新新 范丽亚.四类基于支持向量机的多类分类器的性能比较[J].聊城大学学报(自然科学版) 2014 27( 3) : 54–60.

[22] 王学梅 王凤文 陈滔 等.基于组合模型的 PM2.5 浓度预测及其不确定性分析[J].环境工程 2020 38( 8) : 229–235.

# SVM Classification Implementation of Graphic Texture Detection and Welding Defects Based on Gray Level Co-occurrence Matrix

CHEN Tao<sup>1,2</sup> , ZHANG Qingguo<sup>3</sup> , LIU Ao<sup>4</sup>

( 1.School of Engineering , Anhui Agricultural University , Hefei 230036 , China;

2.School of Civil and Commercial Economic Law , Gansu University of Political Science and Law , Lanzhou 730070 , China;

3.School of Clinical Medicine , Anhui Medical University , Hefei 230031 , China;

4.School of Information & Computer , Anhui Agricultural University , Hefei 230036 , China)

Abstract: In the era of industry 4.0 , as the most basic workpiece processing technology , welding is widely used in various industrial production environments. The quality of welding directly affects the service life of welding products , thus affecting the efficiency of industrial production activities. With the feature extraction of X-ray welding defect image based on , the paper analyzes the classification characteristics of X-ray welding defects , constructs a SVM multi class classifier , and compares the influence of different kernel functions on the classification accuracy. The results are that the SVM classifier based on RBF kernel function can better realize the defect identification and classification , and the overall classification accuracy reaches 92.6%. It provides a simple method for the detection and identification of welding defects.

Keywords: defect identification; feature extraction; SVM classification; kernel function

( 责任编辑: 翟智卫)